

해석 가능한 데이터 기반 모델이 밝혀낸 전류 나선도 진화 — 태양 플레어 예보의 핵심

Interpretable Data-driven Model Reveals Current Helicity Evolution as Key to Solar Flare Forecasting

Youngjae Kim, Yong-Jae Moon(교신저자), Hyun-Jin Jeong, G.S.Choe, Jihyeon Son, Mingyu Jeon

The Astrophysical Journal Letters (ApJL), Vol. 1005, Issue 1, Article L26 (2026)

DOI: 10.3847/2041-8213/ae6cf8 (Gold Open Access, CC-BY)

일러두기 (원문 확보 한계): 본 논문은 출판사 (IOPscience) PDF 원본이 봇 차단으로 확보되지 못해, Open Access HTML 전문과 보충자료 ASCII, 그리고 출판사 이미지 CDN 의 그림 원본을 조합하여 번역했다. 본문 (prose) 은 완전히 확보되었으나, 일부 별행 (displayed) 수식이 원문에서 이미지로 렌더링되어 HTML 추출 과정에서 누락되었다. 핵심 수식 (대표 공식 = 식 (1), 표 1 의 네 표현식) 은 보충자료 ASCII 에서 정확히 복원했으나, 복원 불가능한 정의식·분해식 위치에는 “[별행 수식 — 원문 미확보]” 표시를 정확한 지점에 보존했다.

Contents

통합 전문용어표	3
초록 (Abstract)	3
1 서론 (Introduction)	4
2 데이터 (Data)	5
3 방법 (Method)	6
3.1 딥러닝 모델 (Deep Learning Model)	6
3.2 SR (기호회귀, Symbolic Regression)	7
4 결과 (Results)	8
4.1 딥러닝 모델 평가 (Deep Learning Evaluation)	8
4.2 SR 결과 (SR Results)	8
4.3 대표 해석가능 모델 (Representative Interpretable Model)	8
5 논의 (Discussion)	12
5.1 모델 파라미터의 통계적 분해 (Statistical Decomposition of the Model Parameters)	12
5.2 나선도 응축 (Helicity Condensation) 맥락에서의 해석	12
5.3 모델 파라미터의 시간적 분해 (Temporal Decomposition of the Model Parameters)	15
6 결론 (Conclusion)	15

A 데이터 전처리 (Data Preprocessing)	16
A.1 데이터 필터링 (Data Filtering)	16
A.2 복합 활동영역에 대한 플레어 연관 (Flare Association for Complex ARs)	16
A.3 시계열 구성 및 결측치 대체 (Time Series Construction and Imputation)	17
A.4 레이블링 (Labeling)	17
B 지표 및 교차검증 결과 (Metrics and Cross-validation Results)	17
B.1 보정 및 예보 지표 (Calibration and Forecasting Metrics)	17
B.2 교차검증 결과 (Cross-validation Results)	18
C PySR 전체 표현식 목록 (Full PySR Expression List)	19
문맥 조정 기록	20
남은 한계	20

통합 전문용어표

영어 원문	통일 한국어 번역	챕터별 번역 변이	확정 근거
current helicity	전류 나선도	전 챕터 일관	이미 일관됨
symbolic regression (SR)	기호회귀 (SR)	전 챕터 일관	이미 일관됨
active region (AR)	활동영역 (AR)	전 챕터 일관	이미 일관됨
helicity condensation	나선도 응축	전 챕터 일관	Antiochos(2012) 개념
inverse cascade chunk	역캐스케이드 청크	전 챕터 일관 ch07 에서 1 건 미표기	이미 일관됨 음역 유지, ch07 에 (청크) 병기 보완
polarity inversion line (PIL)	극성 반전선 (PIL)	전 챕터 일관	이미 일관됨
calibrated probability	보정 확률 (활용형: 보정된 확률)	전 챕터 일관	명사형/활용형 구분
isotonic regression	등장회귀	전 챕터 일관	통계학 관용 번역어
harmonic mean	조화평균	전 챕터 일관	이미 일관됨
true skill statistics (TSS)	참 기술 통계량 (TSS)	5 종 변이 존재	ch01 표기로 통일
Heidke skill score (HSS)	하이드케 기술 점수 (HSS)	3 종 변이 존재	ch01 표기로 통일
Brier skill score (BSS)	브라이어 기술 점수 (BSS)	2 종 변이 존재	"skill"=" 기술" 일관 적용
current helicity interaction term	전류 나선도 상호 작용항	띄어쓰기 불일치	공백 없는 표기로 통일
fivefold cross-validation	5 겹 교차검증	띄어쓰기 불일치	공백 없는 표기로 통일

초록 (Abstract)

태양 플레어 (solar flare) 는 지구 근접 우주 공간의 우주환경 (space weather) 에 영향을 미치는 폭발적인 코로나 사건이다. 전류 나선도 (current helicity) 를 포함하여 플레어 발생을 좌우하는 광구 자기장 조건이 아직 불완전하게 규명되어 있어, 플레어 예측은 여전히 어려운 과제로 남아 있다. 자기 파라미터 (magnetic parameters) 에 기반한 경험적 모델 (empirical model) 과 딥러닝 (deep learning) 접근법은 태양 플레어 예보를 발전시켜 왔으나, 전자는 단순화된 통계량에 의존하고 후자는 블랙박스 (black box) 로 작동하여, 예측 결과의 물리적 근원이 명확하지 않다는 한계가 있다. 이 레터 (letter) 에서는 시계열 활동영역 (active region, AR) 자기 파라미터를 이용해 딥러닝과 기호회귀 (symbolic regression, SR) 를 결합함으로써, 해석 가능한 주요 ($\geq M$ 급) 플레어 예보 모델을 제시한다. 우리의 SR 모델은 참 기술 통계량 (true skill statistics, TSS) 0.50 ± 0.17 과 하이드케 기술 점수 (Heidke skill score, HSS) 0.36 ± 0.04 를 달성하여, 딥러닝 기준 모델 (TSS 0.38–0.56, HSS 0.30–0.54) 과 완전히 견줄 만한 성능을 보였으며, 자유도 (degrees of freedom) 는 4 자릿수 이상 더 적은 해석적 수식 (analytical formulae) 만으로 이를 달성했다. 대표 수식 (representative formula) 에 따르면, 플레어 확률은 극성 반전선 (polarity inversion line, PIL) 부근의 자기선속 (magnetic flux, R -값) 에 의해 비선형 게이팅 메커니즘 (nonlinear gating mechanism) 을 통해 좌우되며, 이 메커니즘은 총 전류 나선도와 절대 전류 나선도의 곱이 임계 문턱값 (critical threshold) 을 넘을 때에만 활성화된다. 가장 큰 공간 규모에서의 전류 나선도 제곱합과 강한 상관관계를 보이는 이 전류 나선도 상호작용항 (current

helicity interaction term) 은 예측 분산 (predicted variance) 의 약 77% 를 설명한다. 이 수식은 Community Coordinated Modeling Center(CCMC) 플레어 스코어보드 (flare scoreboard) 모델들이 놓친 AR 12673 및 13664 의 여러 주요 플레어를 성공적으로 식별해냈다. 이러한 결과는 대규모 나선도 축적 (large-scale helicity accumulation) 이 주요 플레어 발생의 핵심 물리적 동인 (primary physical driver) 으로 작용함을 시사한다. 이 발견은 실전 우주환경 예보 (operational space weather forecasting) 에 즉각적인 함의를 지닌다.

1 서론 (Introduction)

태양 플레어 (solar flare) 는 태양 활동영역 (active region, AR) 에 저장된 자기 에너지가 방출되면서 발생하는 갑작스러운 복사 폭발이다 (Shibata & Magara 2011; Green et al. 2018; Fleishman et al. 2020). 이러한 사건은 지구 자기권 (terrestrial magnetosphere) 에 직접적인 영향을 미치고 (Liu et al. 2021), 코로나 물질 방출 (coronal mass ejection, CME) 과 같은 관련 현상을 통해 지상의 위성 운용, 통신 시스템, 전력망을 교란할 가능성이 있기 때문에 (Schrijver 2015) 정확한 예보가 매우 중요하다. 태양 플레어를 촉발하는 물리적 메커니즘이 아직 완전히 규명되지 않았기 때문에, 기존의 다른 경험적 (heuristic) 접근법들보다 결정적으로 우수한 예보 방법을 개발하는 일은 여전히 중대한 과제로 남아 있다. 핵심 질문은 다음과 같다. 다중 규모 (multiscale) 자기 구조가 플레어 발생을 어떻게 유발하는가, 그리고 구체적으로 자기 나선도 (magnetic helicity) 또는 전류 나선도 (current helicity) 가 AR 의 플레어 생산성 (flare productivity) 에서 어떤 역할을 하는가?

자유 자기 에너지 (free magnetic energy) 와 관련된 파라미터, 즉 자기장 비퍼텐셜성 (nonpotentiality) 의 대리 지표 (proxy) 를 기반으로 하거나 (Falconer et al. 2003, 2012; Georgoulis & Rust 2007; Schrijver 2007; Ahmed et al. 2010), 맥킨토시 (McIntosh) 흑점군 분류를 기반으로 한 (Gallagher et al. 2002; Bloomfield et al. 2012; Lee et al. 2012; McCloskey et al. 2018) 다양한 경험적 예보 방법이 제안되어 왔다. 그러나 이러한 모델들은 특정 유형의 비선형 관계를 포착할 수 있지만, 대개 전문가의 사전 지식 (prior knowledge) 으로 미리 정의된 틀 안에서만 최적 모델을 탐색하기 때문에, 기존 전문 지식의 범위를 벗어나는 새로운 관계의 발견을 원천적으로 배제한다. 최근 딥러닝 (deep learning) 의 발전은 향상된 예보 성능을 보여주고 있다 (Huang et al. 2018; Park et al. 2018; Liu et al. 2019). 그럼에도 불구하고 딥러닝 모델은 매우 복잡하여 내부 추론 과정을 이해하기 어렵다. 이러한 해석 가능성 (interpretability) 의 결여는 물리적 이해와의 정합성을 제한하고 신뢰성, 재현성 (reproducibility), 과학적 검증 (scientific validation) 을 저해한다. 또한 모델 개선을 위해 선행 도메인 지식을 통합하는 작업도 복잡하게 만든다.

기존 플레어 예보 연구들은 핵심 입력 데이터를 식별하기 위해 특징 귀속 (feature attribution) 이나 세일리언시 맵 (saliency map) 과 같은 설명 가능 AI(explainable AI) 기법을 활용해 왔지만 (Yi et al. 2021; Sun et al. 2022; Gazula et al. 2024), 이러한 접근법은 명시적이고 물리적으로 의미 있는 함수적 관계를 드러내지는 못한다. 그 결과 경험적 모델이나 딥러닝 접근법 모두 아직 관측된 패턴을 플레어 촉발 메커니즘에 대한 명확하고 정량적인 통찰로 전환하지 못하고 있다. 본 연구에서는 명시적 수식을 추출하기 위해 기호회귀 (symbolic regression, SR) 를 사용한다. 어떤 파라미터가 중요한지만 강조하는 기존의 설명 가능 AI 기법과 달리, SR 은 이러한 파라미터들이 수학적으로 어떻게 결합하는지 (예: 합 또는 곱을 통해) 를 추정한다. 이러한 능력 덕분에 명시적 수식을 추출할 수 있으며, 이는 특징 귀속 기법이 일반적으로 놓치는 심층적인 물리적 통찰을 포착한다.

이 레터에서는 딥러닝과 SR 을 통합하여 높은 예측 정확도와 물리적 해석 가능성을 동시에 달성하는 새로운 태양 플레어 예보 프레임워크 (framework) 를 제시한다. 그림 1 은 우리의 방법론을 도식화한 것이다. 파라미터들 간의 구체적 관계를 조사한 결과, 가장 큰 공간 규모에서의 전류 나선도가 플레어 발생 조건을 조절하는 데 핵심적인 역할을 한다는 사실이 드러났다. 제 2 절에서는 사용한 데이터를 기술하고, 제 3 절에서는 방법론을 소개하며, 제 4 절에서는 결과를 제시하고, 제 5 절에서는 논의를 다루며, 제 6 절에서 결론을 맺는다.

그림 1 상세분석 (figure-analyst 시각 해석 요약): 전체가 하나의 워크플로우 개념도로, 번호




그림 1: 본 연구 방법론의 4 가지 주요 단계. (1) SHARP 파라미터의 24 시간 시계열과 GOES $\geq M$ 급 플레어 발생 여부를 목표값으로 사용한 딥러닝 모델 학습. (2) 입력 시퀀스로부터의 특징 추출. (3) 특징 선택 — 상위 5 개 SHARP 파라미터, 상위 15 개 특징. (4) 선택된 특징으로부터 보정된 딥러닝 확률 추정치로 해석 가능한 수학적 매핑을 추정하는 SR.

가 매겨진 4 단계로 구성된다. (1) 딥러닝 모델 학습 (상단 큰 박스) — 벡터 자기장 지도 시계열 스택 → Input/Deep learning model/Target 3 분할 박스, Target 은 “Yes: 1 / No: 0” 이진 라벨. (2)(3) 특징 추출·특징 선택 — 좌측의 얇은 두 박스가 입력 특징 벡터 x 로 수렴. 우측에서 학습된 모델 출력 $\hat{y}$ 가 내려옴. (4) 기호회귀 (하단 보라색 배너, 이진 트리 아이콘) — x 와 $\hat{y}$ 를 입력받아 최종 산출물 $Prob(\geq M) = f(x)$ 를 도출 (“해석 가능한 플레어 예보 모델”). 색상 언어: 파란색 = 딥러닝 파이프라인, 보라색 = 기호회귀/최종 해석 모델. 캡션과 완전히 일치하며 불일치 사항은 없다. 이 그림은 논문 전체의 방법론 로드맵으로, 이진 라벨이 아니라 **보정 확률**을 SR의 타겟으로 삼는다는 점이 이후 그림 2.3의 확률 시계열을 이해하는 전제가 된다.

2 데이터 (Data)

우리는 모델 입력으로 R -값 (R -value; Schrijver 2007) 과 AREA_ACR 을 포함한 18 개의 우주기상 HMI 활동영역 패치 (Space-weather HMI Active Region Patch, SHARP) 파라미터 (Bobra et al. 2014) 를 사용한다. 이 자료는 2010 년 10 월부터 2023 년 12 월까지 96 분 간격으로 수집했다. 96 분이라는 샘플링 간격은 플레어 예보와 관련된 활동영역 (active region, AR) 자기장 진화를 포착하기에 충분한 시간 분해능을 유지하면서도 데이터 활용 효율을 최적화하기 위해 선택했다. 우리는 태양동역학관측위성 (Solar Dynamics Observatory; Pesnell et al. 2012) 에 탑재된 헬리오시스믹·자기장 촬영기 (Helioseismic and Magnetic Imager, HMI; Scherrer et al. 2012) 의 확정본 (definitive) 원통형 등면적 (cylindrical equal-area) SHARP 자료를 공동과학운영센터 (Joint Science Operations Center) 를 통해 확보하여 활용했다. 데이터셋의 신뢰성을 확보하기 위해 경도 필터링과 품질 검사를 포함한 엄격한 데이터 선별 기준을 적용했다 (세부 내용은 부록 A 참조). 우리는 24 시간 관측 구간 (observing window) $[t - 24 \text{ hr}, t]$ 와 24 시간 예보 구간 (forecasting window) $(t, t + 24 \text{ hr}]$ 을 정의했으며, 여기서 t 는 플레어 발생 시각이 아니라 관측 구간의 마지막 시점을 나타낸다. 각 관측 구간 내에서 18 개의 SHARP 파라미터를 96 분 간격으로 샘플링하여, 파라미터별로 길이 16 의 입력 시퀀스 (input sequence) 를 얻는다. 이 시퀀스는

해당 AR의 자기장 진화를 특징짓는다. 예보 구간을 기준으로 각 시퀀스는 플레어 발생 (flaring, M 급 이상 사건 존재) 또는 평온 (quiet, M 급 이상 플레어 없음) 으로 라벨링된다 (세부 내용은 부록 A 참조). 특히 플레어가 발생하지 않은 영역, 즉 해당 예보 구간에 M 급 이상 플레어가 없는 모든 영역의 시퀀스는 평온 (quiet) 클래스에 포함된다.

우리는 딥러닝 모델의 공정한 학습과 평가를 보장하기 위해, 훈련 세트 (training set) 에서만 도출한 통계량 (평균과 표준편차) 을 이용해 각 파라미터를 표준화 (standardize) 했다. 이 표준화는 안정적인 최적화 (optimization) 를 위한 수치 전처리 단계일 뿐이며, 파라미터가 정규분포 (Gaussian distribution) 를 따른다고 가정하는 것은 아니다. 기호회귀 (symbolic regression, SR) 는 원본의 비표준화 (unstandardized) 데이터에 대해 수행되며, 이를 통해 차원 (dimensional) 정보를 그대로 보존한다.

3 방법 (Method)

우리는 데이터 기반 패턴 추출 (data-driven pattern extraction) 과 물리적 해석 가능성 (physical interpretability) 을 동시에 달성하기 위해, 딥러닝과 기호회귀 (symbolic regression, SR) 를 결합한 태양 플레어 예보 프레임워크 (framework) 를 개발했다. 길이 16 시퀀스로 샘플링된 18 개의 SHARP 입력 파라미터 (2 절) 로부터 출발하여, 우리는 1242 개의 후보 특징 (candidate feature; 3.2 절) 을 도출하고, 이 중 단계적 선별 (staged screening) 과정을 거쳐 대표 모델 탐색 (representative model search) 에 사용할 15 개의 SR 입력 특징을 선택한다. 딥러닝 구성요소 (component) 는 모델 형태에 대한 사전 정의된 분포 가정 없이 이진 플레어 발생 데이터로부터 연속적인 예측 (가능도) 점수를 학습한다 (이는 학습된 매핑 (mapping) 을 가리키는 것이며, 앞서 설명한 선형 입력 스케일링 (scaling) 과는 다른 개념이다). 이어서 SR 은 이 매핑을 간결한 해석적 표현식 (analytical expression) 으로 근사한다. 이 파이프라인 (pipeline) 에서 딥러닝은 비선형 시간적 진화 (nonlinear temporal evolution) 를 모델링하고, 등장회귀 (isotonic regression) 보정 (calibration) 은 원점수 (raw score) 를 확률 추정치로 변환하며, 단계적 특징 선별은 SR 을 다루기 쉬운 (tractable) 수준으로 유지하고, PySR 은 여러 SR 프레임워크 중 구조적 재현성 (structural reproducibility) 이 가장 우수하다는 이유로 (Brum et al. 2026) 명시적 해석적 수식을 얻는 데 사용된다.

3.1 딥러닝 모델 (Deep Learning Model)

우리는 클래스 불균형 (class imbalance) 문제를 다루기 위해 가중 교차 엔트로피 (weighted cross-entropy) 와 가중 브라이어 기술 점수 (weighted Brier skill score, BSS; Brier 1950) 손실을 결합한 FLARE 손실 (FLARE loss; Takagi et al. 2025) 및 그에 대응하는 영향 균형 (influence-balanced, IB) 버전을 사용하여, 원본 훈련 세트 분포 그대로 딥러닝 모델을 학습시켰다. 이 복합 목적함수 (composite objective) 는 다수 클래스에 대한 과신 (overconfidence) 을 최소화하는 동시에 확률적 기술 (probabilistic skill) 을 직접 최적화한다. 우리는 장단기 메모리 (long short-term memory, LSTM), LSTM-어텐션 (attention), 양방향 LSTM (bidirectional LSTM, BiLSTM), BiLSTM-어텐션 등 네 가지 아키텍처 (architecture) 를 학습·평가했다. 각 모델은 두 개의 LSTM 또는 BiLSTM 층, 추가적인 어텐션 층 ("attention" 이라고 명시적으로 지정된 모델에만 포함), 그리고 하나의 선형 층 (linear layer) 을 순차적으로 구성한다. 어텐션 층은 다양한 유사도 함수 (similarity function) 를 사용해 시퀀스 구성요소 간의 소프트맥스 (softmax) 가중 유사도를 계산한다. 우리는 Luong et al.(2015) 이 제안한 어텐션 메커니즘 (attention mechanism) 을 채택했으며, 이는 이전에 태양 플레어 예보 연구 (Liu et al. 2019) 에서도 사용된 바 있다. LSTM 과 BiLSTM 은 시계열 추론 (time series inference) 에 최적화된 신경망 아키텍처로서, 각각 단방향과 양방향으로 정보를 처리한다. LSTM 층의 은닉층 크기 (hidden layer size, 은닉 상태 차원 (hidden-state dimensionality)) 이며 물리적 파라미터가 아닌 아키텍처 하이퍼파라미터 (hyperparameter) 이다) 는 64 이다. BiLSTM 모델에서는 동일한 은닉층 크기를 유지하면서 LSTM 블록을 양방향 LSTM 블록으로 대체했다. 우리는 딥러닝 모델을 평가하기 위해 5 겹 교차검증 (fivefold cross-validation, 훈련 80%-시험 20%) 을 사용했다. 시퀀스는 분할 이전에 AR 별로 그룹화하여 각 AR 의 모든 시

퀀스가 동일한 폴드 (fold) 에 남도록 했다. 이는 데이터 누출 (data leakage) 을 방지하고 훈련 세트와 시험 세트 간의 물리적 독립성 (physical independence) 을 보존한다. TSS(참 기술 통계량) 와 HSS(하이드케 기술 점수) 의 조화평균 (harmonic mean) 이 가장 높은 모델을 이후 SR 분석에 사용할 모델로 선정한다. 딥러닝 모델의 선형 층은 두 개의 로짓 (logit) 을 출력하며, 이는 두 클래스 (플래어 발생·평온) 에 대한 소프트맥스를 거쳐 예측 점수로 변환된다. 현대의 심층 신경망 (deep network) 은 원점수에서 흔히 과신 (overconfident) 하는 경향을 보이므로 (Guo et al. 2017), 확률적 해석에 앞서 보정이 필요하다. 소프트맥스 출력은 잘 보정된 확률이라기보다 가능한 점수를 나타내므로, 우리는 등장회귀 (isotonic regression) 를 이용해 점수를 보정 확률로 매핑했다 (Zadrozny & Elkan 2002). 이러한 선택은 보정 데이터가 충분할 경우 등장회귀가 유리할 수 있다는 기존 근거 (Niculescu-Mizil & Caruana 2005) 로도 뒷받침된다. 이후 우리는 이 등장회귀로 보정된 확률을 SR 학습에 사용하여, 결과에 대한 더 엄밀한 확률적 평가를 가능하게 한다.

3.2 SR (기호회귀, Symbolic Regression)

SR 은 정확도와 복잡도 사이의 균형을 유지하면서 입력 특징 $\mathbf{x}$ 를 목표값 y 로 매핑하는 함수를 찾기 위해 후보 수학적 표현식 (candidate mathematical expression) 의 공간을 탐색한다. 통상적인 회귀 (regression) 와 달리, SR 은 계수 (coefficient) 뿐 아니라 함수 형태 (functional form) 자체도 추정한다. 이 레터 (Letter) 에서 우리는 최근 벤치마크 (Brum et al. 2026) 에서 여러 SR 프레임워크 중 가장 높은 구조적 재현성을 보인 진화적 (evolutionary) SR 프레임워크인 PySR(Cranmer 2023) 을 사용하여, 입력 시퀀스로부터 도출한 특징과 학습된 딥러닝 모델이 추론한 보정된 플래어 확률 사이의 해석 가능한 관계를 추출했다. SR 은 제한된 연산자 라이브러리 (operator library) 와 유한한 탐색 예산 (search budget) 내에서 탐색을 수행하므로, 도출된 표현식은 가능한 모든 함수 형태를 총망라한 표현이 아니라 그 제한된 탐색 공간 내에서의 최적 근사 (best-fit approximation) 로 해석해야 한다. 각 24 시간 시퀀스로부터 우리는 세 가지 유형의 특징을 구성한다. 각 시간 단계 (time step) 에서의 파라미터 값, 사비츠키-골레이 필터 (Savitzky–Golay filter; Savitzky & Golay 1964) 를 이용해 계산한 1 차·2 차 시간 미분값, 그리고 파라미터 값과 그 시간 미분값 각각으로부터 계산한 일곱 개의 통계 지표 (평균, 표준편차, 최댓값, 최솟값, 중앙값, 첨도 (kurtosis), 왜도 (skewness)) 이다. 이를 통해 1242 개의 후보 특징이 생성된다. PySR 을 비롯한 유전 프로그래밍 (genetic programming) 기반 SR 방법들은 고차원 입력 특징에서 수렴 (convergence) 문제를 겪는다. SR 의 수렴을 보장하기 위해 우리는 2 단계 특징 선택 (two-stage feature selection) 을 수행한다. 먼저, 최고 성능 딥러닝 모델에 대한 순열 기반 중요도 (permutation-based importance) 평가를 통해 가장 중요한 상위 다섯 개 SHARP 파라미터를 식별한다. 그 다음 후보 특징을 이 다섯 개 파라미터에서 파생된 것으로 제한하고, 이 부분집합 (subset) 에 대해 랜덤 포레스트 (random forest) 를 학습시킨 뒤, 불순도 기반 특징 중요도 (impurity-based feature importance, 불순도 평균 감소량 (mean decrease in impurity)) 가 높은 상위 15 개 특징을 SR 용으로 선택한다. 안정적인 경사 (gradient) 수렴을 위해 입력 표준화가 필요한 딥러닝 모델과 달리, 우리는 SR 에서 선택된 특징에 대해 원본의 비표준화 값을 그대로 사용한다. 이 접근법은 물리적 단위와 차원 정보를 보존함으로써, 서로 다른 물리량 (예: 자기선속 (magnetic flux) 대 전류 나선도 (current helicity)) 간의 상대적 스케일 (scale) 을 본질적으로 반영하는 계수를 모델이 추정할 수 있게 한다. 나아가 PySR 이 채택한 확률적 탐색 (stochastic search) 메커니즘은 입력 스케일 변화에 강건 (robust) 하여, 물리적 해석 가능성을 유지하면서도 정규화 (normalization) 가 필요 없게 만든다.

SR 은 다섯 개의 이항 연산자 (binary operator: 덧셈, 뺄셈, 곱셈, 나눗셈, 거듭제곱) 와 두 개의 단항 연산자 (unary operator: 지수함수, 로그함수) 로 구성된 연산자 라이브러리를 이용해 구현된다. 우리는 TSS 와 HSS 의 조화평균이 가장 높은 딥러닝 모델을 사용하며, 검증 세트 (validation set) 만을 이용해 등장회귀를 적용하여 보정 확률을 얻고, 이 보정된 출력값을 SR 의 목표값 (target) 으로 사용한다. SR 학습에 한해, 우리는 (딥러닝 출력을 로짓 변환 (logit transformation) 한 뒤) 훈련 세트에 무작위 언더샘플링 (random undersampling) 을 적용했다. 이는 FLARE 손실의 영향 균형 (IB) 항이 SR 에는 적용될 수 없는 데다, 이 전략이 SR 에 대해 더 나은 조화평균을 산출했기 때문이다. PySR 모델의 목표 변수는 플래어 발생 여부의 이진 실측 라벨 (ground truth label, 0 또는 1) 이 아니라, 선택된 딥러닝 모델이 출력한 (등장회귀로 보정된 확률을 포함한) 연

속적인 확률 점수 (0.0 에서 1.0 사이) 이다. 우리가 이러한 대리 모델링 (surrogate modeling) 접근법을 채택한 이유는, 딥러닝 모델의 출력이 희소한 이진 라벨보다 더 매끄러운 대리 목표 (surrogate target) 를 제공하여, 우리의 제한된 연산자 라이브러리 내에서 SR 이 더 안정적인 연속 매핑을 적합 (fit) 할 수 있게 하기 때문이다. 실측값 (ground truth) 대비 SR 비교를 위해서는, 동일하게 필터링된 입력값과 동일한 특징 구성·연산자 설정을 사용하며, 목표값만 다르다 (이진 라벨 대 보정된 딥러닝 출력). 우리는 딥러닝 모델 출력으로 학습한 SR 이 실측값으로 직접 학습한 $SR(0.23 \pm 0.02)$ 보다 더 높은 TSS-HSS 조화평균 (0.40 ± 0.05) 을 산출함을 확인했으며, 이는 우리의 대리 모델링 접근법의 효과를 검증한다.

우리는 SR 방법론을 평가하기 위해 동일한 5 겹 교차검증을 적용한다. 각 폴드에 대해 선택된 특징을 입력으로, 등장회귀로 보정된 딥러닝 확률 추정치를 목표값으로 하여 SR 을 학습시킨 뒤, 실측 플레어 발생 여부에 대해 시험한다. 아울러 우리는 훈련-시험 분할 없이 전체 데이터셋에 SR 을 적용하여 대표 수식 (representative formula) 을 도출한다. 이 전체 데이터셋 적합 (full dataset fitting) 에서 목표 변수는 다섯 개 폴드 전체의 보정된 딥러닝 모델 출력값의 평균으로, 샘플당 하나의 값을 산출한다. 4.3 절에 제시하는 이 단일 표현식은 성능 추정이 아니라 순전히 물리적 해석을 위한 것이다.

4 결과 (Results)

4.1 딥러닝 모델 평가 (Deep Learning Evaluation)

우리는 개별 활동영역 (active region, AR) 기반 분할 전략을 적용한 5 겹 교차검증 (fivefold cross-validation) 으로 모든 딥러닝 모델을 평가했다. 평가 결과는 부록 B 에 제시했다. BiLSTM-attention 모델이 평가한 모든 지표 중 TSS 와 HSS 의 조화평균이 가장 높았으며 (0.47 ± 0.14), 보정 (calibration) 이전 기준으로 오경보율 (FAR) = 0.25 ± 0.09 , 정밀도 (precision) = 0.75 ± 0.09 를 기록했다. 이에 따라 이 모델을 이후 기호회귀 (symbolic regression, SR) 분석 대상으로 선정했다.

4.2 SR 결과 (SR Results)

SR 모델의 5 겹 교차검증 결과 역시 부록 B 에 제시했다. 이 결과는 최고 성능 딥러닝 모델과 견줄 만한 성능 지표를 보여준다. 주목할 점은, BiLSTM-attention 모델의 142,594 개 모델 계수 (model coefficient) 에서 SR 모델의 10 개 미만 계수로 모델 복잡도가 극적으로 줄었음에도 이러한 수준의 예측 정확도가 유지된다는 것이다.

4.3 대표 해석가능 모델 (Representative Interpretable Model)

물리적 해석을 위해, 우리는 전체 데이터셋 (모든 분할을 결합한 것) 에 SR 을 적용했으며, 이때 목표값 (target) 으로는 다섯 개 폴드 (fold) 전체에서 얻은 보정된 BiLSTM-attention 출력값의 평균 (샘플당 하나의 값) 을 사용했다. 특징 선택 (feature selection) 결과, 네 개의 SHARP 파라미터에서 유도된 15 개의 SR 입력 특징 (feature) 이 확인되었다. 즉, R (최대값, 최소값, 평균값, 중앙값, 그리고 12 번째·13 번째·14 번째·15 번째 시간 스텝 값); $[G \text{ Mm}^{-1}]$ 단위를 갖는 파라미터 (최대값과 최소값); 그리고 $[둘 다 G^2 \text{ m}^{-1} \text{ 단위인}]$ 파라미터 (하나는 15 번째 시간 스텝과 최대값; 다른 하나는 14 번째·15 번째 시간 스텝과 최대값) 이다. PySR 은 병렬 탐색 (parallel search) 과, 탐색 (exploration) 에서 활용 (exploitation) 으로 전이하는 모의 담금질 (simulated annealing) 기법을 이용해 이 특징들로부터 해석 가능한 모델을 도출한다 (Cranmer 2023).

[주: 위 문단에서 네 개 SHARP 파라미터 중 두 번째 (R 다음) 와 세 번째·네 번째 파라미터의 기호는 원문에서 인라인 수식 이미지로 표기되어 HTML 추출 시 누락되었다. 문맥상 각각 전류밀도/전류 나선도 (current helicity) 관련 파라미터로, 단위 ($G \text{ Mm}^{-1}$, $G^2 \text{ m}^{-1}$) 로 식별된다. 정확한 기호는 아래 대표 공식·표 1 의 H_{total} , H_{abs} 를 참조하라.]

PySR 은 (표현식 트리의 노드 개수로 정의되는) 복잡도 (complexity) 가 서로 다른 표현식들을 생성하며, 각 복잡도 수준에서 평균제곱오차 (mean-squared error, MSE) 를 최적화한다 (표 1). 구조적 제약과 진화적 선택 (evolutionary selection) 으로 인해 복잡도 수준은 불연속적으로 나타난다. 우리가 설정한 최대 복잡도 제약 (20) 하에서, 표 1 은 간결성을 위해 MSE 가 가장 작은 상위 네 개 표현식만을 제시한다. 모든 복잡도 수준에 걸친 표현식 전체 목록과 정확한 수치 상수는 부록 C 에 제시했다. 성능이 비슷한 최고 복잡도 후보들 가운데, 우리는 물리적 해석을 위한 대표 공식 (representative formula) 으로 MSE 가 가장 작은 복잡도 20 표현식을 선정했다. 대형 플레어 (major flare) 확률의 로짓 (logit) 은 다음과 같이 주어진다.

식 (1) (= 표 1 의 복잡도 20 표현식, 보충자료 ASCII 에서 복원):

$$\text{logit}(P_{\geq M}(t)) = C_1 R(t - 2\Delta t) R(t) - \frac{C_2}{R^2(t - 3\Delta t) H_{c_{\text{total}}}(t) H_{c_{\text{abs}}}(t_{\text{max}}) + C_3} - C_4$$

여기서 $P_{\geq M}(t)$ 는 구간 $(t, t + 24 \text{ hr}]$ 내에 M 급 이상 플레어가 적어도 한 번 발생할 확률을 나타내며, 전류 나선도 (current helicity) 항인 $H_{c_{\text{total}}}$ (전체/순 전류 나선도, total/net current helicity) 와 $H_{c_{\text{abs}}}$ (절대 전류 나선도, absolute current helicity) 가 포함되고, Δt 는 샘플링 간격 (sampling step) 이다. 이 모델은 순간 (instantaneous) 값 (t 시점의 $H_{c_{\text{total}}}$) 과 과거 최고 (peak historical) 값 (t_{max} 시점의 $H_{c_{\text{abs}}}$) 의 나선도 값을 모두 결합한다.

[별행 수식 정의 — 원문 미확보. 원문에서 $H_{c_{\text{total}}}$, $H_{c_{\text{abs}}}$ 의 정의식이 이 지점에 이미지로 표시되었을 수 있으나 HTML 추출 불가하다. 인접 본문 (§5.1) 과 그림 3(e) 범례에서 관련 정의를 확인할 수 있다.]

딥러닝 모델과 달리, SR 은 명시적 (explicit) 수학 표현식을 산출하므로 해석적 다루기 쉬움 (analytical tractability) 이라는 뚜렷한 이점을 갖는다. 이러한 투명성 (transparency) 을 활용하여, 우리는 1 차 테일러 전개 (first-order Taylor expansion) 에 기반한 분산 분해 (variance decomposition) 방법으로 각 항의 기여도를 엄밀하게 정량화했다. 결정적으로, 유도된 방정식에 내재된 비선형 상호작용 (nonlinear interaction) 항을 반영하기 위해, 우리는 개별 파라미터가 아니라 통합된 특징 그룹 (integrated feature group) 의 민감도 (sensitivity) 와 분산 (variance) 을 계산했다. 그룹별 분산 기여도 분석 결과, 전류 나선도 상호작용항 (current helicity interaction term) 이 두드러지게 지배적임이 드러났다. 모델의 방정식 구조와 일치하는 통합 특징들을 분석했을 때, 두 나선도 파라미터의 곱 ($H_{c_{\text{total}}}(t) H_{c_{\text{abs}}}(t_{\text{max}})$) 이 예측 확률의 전체 분산 중 약 77% 를 설명했다. 이에 반해, 에너지 구동원 (energy driver) 역할을 하는 자기선속 (magnetic flux) 곱항 ($R(t) \cdot R(t - 2\Delta t)$) 의 기여도는 약 14.5% 에 불과했다. 이러한 격차는 이 모델을 자기선속 제한형 (flux-limited) 이 아니라 "위상 제한형 (topology-limited)" 으로 근본적으로 특징짓는다. 전류 나선도 곱 ($G^4 \text{ m}^{-2}$ 단위를 갖는 $H_{c_{\text{total}}}(t) H_{c_{\text{abs}}}(t_{\text{max}})$ 에 대해 계산됨) 의 평균 대비 막대한 표준편차 ($\sigma \approx 9.3 \times 10^5$) 는 플레어 발생 조건이 활동영역 (AR) 의 "결맞은 비퍼텐셜성 (coherent nonpotentiality)" 에 매우 민감함을 시사한다. 본질적으로, SR 모델은 높은 자기선속이 필요조건적 기준선 (baseline) 이기는 하지만, 플레어 촉발의 결정적 스위치이자 예측 불확실성의 주된 원인은 모델의 억제 임계값 (suppression threshold) 을 넘어서는 크기의 전류 나선도가 나타내는 큰 규모와 비대칭성 (asymmetry) 의 존재라는 점을 시사한다.

Table 1
Evolutionary Selected Complexities and Their Best Results from the PySR Framework

Complexity	MSE	Equation
20	1.112	$C_1 R(t - 2\Delta t) R(t) - \frac{C_2}{R^2(t - 3\Delta t) H_{c_{\text{total}}}(t) H_{c_{\text{abs}}}(t_{\text{max}}) + C_3} - C_4$
19	1.114	$C_5 R(t - 2\Delta t) R(t) - \frac{C_6}{R(t - 3\Delta t) H_{c_{\text{total}}}(t) H_{c_{\text{abs}}}(t_{\text{max}}) + C_7} - C_8$
17	1.131	$C_9 R(t - 3\Delta t) R(t) - \frac{C_{10}}{H_{c_{\text{total}}}(t) H_{c_{\text{abs}}}(t_{\text{max}}) + C_{11}} - C_{12}$
15	1.165	$C_{13} R(t - 2\Delta t) R(t) - \frac{C_{14}}{R(t - 3\Delta t) H_{c_{\text{abs}}}(t_{\text{max}}) + C_{15}} - C_{16}$

Note. Here, C_n collectively denotes constant coefficients (fitted by PySR).

표 1 의 출판사 원본 이미지.

표 1 상세분석: 3 열 (복잡도·MSE·표현식) 4 행 구조. 복잡도가 낮아질수록 MSE 가 소폭 증가 (1.112→1.165) 하며, 모든 표현식이 공통 골격을 공유한다. 복잡도가 줄수록 분모의 $R^2(t - 3\Delta t) \cdot R(t - 3\Delta t)$ 플럭스 인자나 $H_{c_{\text{total}}}$ 항이 순차적으로 탈락한다. 캡션·본문 전사와 정확히 일치한다. 대표 모델은 최소 MSE 의 복잡도 20 표현식 (= 식 (1)) 이다.

표 2: PySR 프레임워크에서 진화적으로 선정된 복잡도들과 그 최적 결과 (수식은 보충자료 ASCII 에서 복원).

복잡도	MSE	표현식
20	1.112	$C_1 R(t - 2\Delta t) R(t) - \frac{C_2}{R^2(t - 3\Delta t) H_{c_{total}}(t) H_{c_{abs}}(t_{max}) + C_3} - C_4$
19	1.114	$C_5 R(t - 2\Delta t) R(t) - \frac{C_6}{R(t - 3\Delta t) H_{c_{total}}(t) H_{c_{abs}}(t_{max}) + C_7} - C_8$
17	1.131	$C_9 R(t - 3\Delta t) R(t) - \frac{C_{10}}{H_{c_{total}}(t) H_{c_{abs}}(t_{max}) + C_{11}} - C_{12}$
15	1.165	$C_{13} R(t - 2\Delta t) R(t) - \frac{C_{14}}{R(t - 3\Delta t) H_{c_{abs}}(t_{max}) + C_{15}} - C_{16}$

주. 여기서 C_n 은 (PySR 이 적합시킨) 상수 계수들을 통칭하여 나타낸다.

그림 2(a) 는 대표 모델에서 플레어 확률과 명시적으로 상관관계를 갖는 두 항을 축으로 하는 평면 상에서의 추론 결과를 보여준다. x 축은 $H_{c_{total}}(t) H_{c_{abs}}(t_{max})$ 이고, y 축은 $R(t - 2\Delta t) R(t)$ 이다. 왼쪽 하위 그림은 딥러닝 모델의 보정 확률 (calibrated probability) 을 보여주고, 오른쪽 하위 그림은 각 구간 (bin) 에서 양성 (플레어 발생) 샘플이 전체 샘플에서 차지하는 비율을 보여준다. 청록색 사각형으로 표시된 영역 내에서, 딥러닝 모델은 불확실한 보정 확률을 산출하는 반면, SR 모델은 훨씬 낮은 복잡도로도 높은 확률을 예측한다. 특히 이 영역은 전적으로 양성 샘플로만 구성되어 있어, 딥러닝 모델이 놓칠 수 있는 핵심 패턴을 SR 모델이 포착하는 능력을 잘 보여준다.

그림 2 상세분석: (a) 좌우 두 산점도/히트맵이 축을 공유한다. 공통 x 축은 이미지 라벨 기준 $R^2(t - 3\Delta t) \cdot H_{c_{total}}(t) \cdot H_{c_{abs}}(t_{max})$ [G^4/m^2](식 (1) 분모 전체), 공통 y 축은 $R(t) \cdot R(t - 2\Delta t)$ 이다. 좌측 “DL output” 은 낮은 $x \cdot y$ 에서 파랑 (저확률) 이 $y \cdot x$ 가 커질수록 빨강 (고확률) 으로 전이하는 산점도이며, 상단 청록 사각형 영역은 중간색 (불확실) 으로 나타난다. 우측 “positive ratio” 히트맵에서는 동일 청록 영역이 순수 빨강 (양성비 1) 으로 나타나, DL 이 불확실해하는 영역이 실제로는 전부 양성 샘플임을 보여준다. (b) AR 13664(2024-05) 와 AR 12673(2017-09) 두 사례 모두에서 보라색 (Our Model) 확률 곡선이 실제 대형 플레어 발생 시점과 잘 맞물려 상승한다.

역주 (캡션-이미지 불일치): 캡션.본문은 패널 (a) 의 x 축을 $H_{c_{total}}(t) H_{c_{abs}}(t_{max})$ (헬리시티 곱만) 로 기술하나, 실제 이미지의 x 축 라벨은 $R^2(t - 3\Delta t) \cdot H_{c_{total}}(t) \cdot H_{c_{abs}}(t_{max})$ 로 $R^2(t - 3\Delta t)$ 인자가 추가된 식 (1) 분모 전체이다. 이는 캡션의 단순화 표기이며, 이미지 쪽이 더 완전한 표현으로 판단된다.

역할: 논문의 정량 성능 근거. (a) 는 SR 이 DL 의 불확실 영역에서도 확실한 양성 패턴을 포착함을 보이고, (b) 는 역사적 대형 사건에서의 실전 예보 사례로 SR 모델의 정성적 우수성을 보여준다.

그림 2(b) 는 우리 SR 모델이 두 개의 매우 활동적인 활동영역에 대해 보인 예보 성능을 보여준다. 이 두 AR 은 각각 태양활동주기 (solar cycle) 25 와 24 에서 가장 강력한 지구자기영향 (geoeffective) CME 와 연관되어 있다. 이용 가능한 경우, 아카이브된 NOAA 예보와 CCMC(Community Coordinated Modeling Center) 의 경험적 모델들도 비교 분석을 위해 함께 포함했다. 이 패널들은 CCMC 모델에 대한 체계적 벤치마크 (systematic benchmark) 라기보다는 정성적 사례 연구 (qualitative case study) 로 의도된 것이다. 오경보 구간 (false alarm interval; 높은 예측 확률에도 실제 대형 플레어가 관측되지 않은 경우) 이 나타날 수 있으며, 이는 단일 모델을 임계값 기반으로 해석하는 방식의 한계를 잘 보여준다. 각 시계열 패널 위쪽의 수평 띠는 이용 가능한 각 모델에 대해 0.5 확률 임계값에서의 정답/오답 예보 구간을 요약하며 (녹색: 정답, 빨간색: 오답), 이를 통해 이러한 오경보 구간을 명시적으로 드러낸다. 다른 이용 가능한 모델들과 겹치는 시간 구간 내에서, 이번 사례 연구 비교에서 우리 SR 모델이 가장 긴 누적 성공 구간을 보였다.




그림 2: 대표 SR 모델의 성능. 패널 (a): 플레어 확률과 명시적으로 상관관계를 갖는 대표 모델의 두 항목으로 이루어진 평면. 왼쪽: 딥러닝 모델의 보정 확률. 오른쪽: 각 구간에서 양성 대 전체 샘플의 비율. 패널 (b): AR 13664 및 AR 12673에 대한 예보 사례.

5 논의 (Discussion)

5.1 모델 파라미터의 통계적 분해 (Statistical Decomposition of the Model Parameters)

SR 모델은 $H_{c_{total}}(t) H_{c_{abs}}(t_{max})$ 에 의해 명시적으로 조절되는 플레어 확률을 산출한다. 이 곱셈항을 물리적으로 해석하기 위해 (여기서는 시간적 측면은 잠시 배제한다), 먼저 전류 나선도 밀도 (current helicity density) 를 다음과 같이 정의한다.

[별행 수식 — 원문 미확보] — 본문에 따르면 전류 나선도 밀도는 수직 성분만을 사용하여 $h_c = B_z (\nabla \times \mathbf{B})_z$ 형태로 정의된다 (아래 문장 참조).

이 정의는 표준 SHARP 요약 파라미터에서 이용 가능한 수직 성분 (B_z 와 $(\nabla \times \mathbf{B})_z$) 만을 사용하며, 수평 전류 성분 (J_x, J_y) 은 포함하지 않는다는 점에 유의해야 한다. 따라서 본 연구에서 사용하는 “전류 나선도 (current helicity)” 와 “전류 (electric current)” 라는 용어는 이러한 수직 성분 대리변수 (proxy) 를 가리키며, 이는 본 분석의 한계에 해당한다.

관심 파라미터들은 다음과 같이 표현할 수 있다.

[별행 수식 — 원문 미확보] — $H_{c_{total}}, H_{c_{abs}}$ 를 S_+ (양의 부호 영역) 와 S_- (음의 부호 영역) 에 대한 적분/합으로 표현하는 정의식이다.

여기서 $S_+(S_-)$ 는 전류 나선도 밀도가 양 (음) 의 부호를 갖는 영역을 가리킨다. 이 두 파라미터의 곱은 다음과 같이 분해할 수 있다.

[별행 수식 — 원문 미확보] — $H_{c_{total}} \cdot H_{c_{abs}}$ 의 곱 분해식이다.

이는 다시 평균 (mean) 과 분산 (variance) 에 관련된 두 항으로 더 세분화되며, 이하 식에서 각각 MEAN 과 VAR 로 표기한다.

[별행 수식 — 원문 미확보] — MEAN·VAR 분해식이다. 그림 3(e) 범례에서 다음 형태로 확인된다.

$$\begin{aligned} \text{MEAN} &= N_+^2 \mathbb{E}_+(h_c) - N_-^2 \mathbb{E}_-(h_c) \\ -\text{VAR} &= -(N_+^2 \text{Var}_+(h_c) - N_-^2 \text{Var}_-(h_c)) \end{aligned}$$

여기서 $N_{\pm}$ 는 각각 양/음 부호 영역의 픽셀 수이며, $\mathbb{E}_{\pm}$ 와 $\text{Var}_{\pm}$ 는 해당 영역에서의 전류 나선도 밀도 h_c 의 평균과 분산이다.

우리의 해석 가능한 데이터 기반 (data-driven) 모델은 태양 플레어 예보가 주로 활동영역 (AR) 의 전류 나선도 분포에서 유도된 이 두 상보적 (complementary) 통계항에 의존한다는 사실을 보여준다.

5.2 나선도 응축 (Helicity Condensation) 맥락에서의 해석

VAR 항은 인접 영역이 유사한 전류 나선도 값을 갖는다는 가정 하에 작동하며, 활동영역 전체에 걸친 전류 나선도 분포의 공간적 이질성 (spatial heterogeneity) 을 포착하는 것으로 보인다. 나선도 응축 (helicity condensation; Antiochos 2012) 의 맥락에서, 나선도는 초입자 (supergranule) 크기에 가까운 작은 규모에서 0 에 가까운 작은 크기로 생성된 뒤, 활동영역 전체에 균일하게 분포하는 대신 자기 재결합 (magnetic reconnection) 을 통해 극성 반전선 (polarity inversion line, PIL) 인근의 가장 큰 규모로 농축된다. 선형 무힘장 (linear force-free field) 의 경우 전류 나선도

(current helicity) 와 자기 나선도 (magnetic helicity) 는 서로 정비례한다. 태양 대기가 엄밀한 의미의 선형 무힘장은 아니지만, Tziotziou et al.(2012) 과 Toriumi & Takasao(2017) 는 각각 자기 나선도와 전류 나선도가 자유 에너지 (free energy) 와 강한 상관관계를 보인다는 사실을 확인했다. 따라서 전류 나선도는 자기 나선도의 대리변수 (proxy) 로 사용할 수 있다. 관측된 응축 현상은 준 2 차원 (quasi-2D) 계에서의 MHD 난류 (MHD turbulence) 역학과 부합한다. 2 차원 MHD 에서 스펙트럼 에너지 전달 (spectral energy transfer) 의 방향은 여전히 논쟁의 대상이지만 (Fyfe & Montgomery 1976), 자기 퍼텐셜의 제곱평균 (mean-squared magnetic potential) 이나 자기 나선도와 같은 자기 불변량 (magnetic invariant) 의 역캐스케이드 (inverse cascade) 는 강건한 특징으로 알려져 있다 (Pouquet et al. 1976). 결정적으로, 자기 나선도와 에너지는 실현가능성 조건 (realizability condition) $|H(k)| \leq 2E(k)/k$ 를 통해 스펙트럼상으로 결합되어 있다. 이 제약 조건은 역캐스케이드에 의해 구동되는 큰 규모 (작은 k) 에서의 나선도 축적이 동일한 규모에서 상당한 자기 에너지의 존재를 필연적으로 수반함을 의미한다. 결과적으로 이 계는 자기 에너지를 크고 결맞은 (coherent) 집중 구조로 효과적으로 조직화하는데, 이는 2 차원 난류에서 자기 아일랜드 (magnetic island) 들이 합쳐지는 과정과 유사하다.

이 가설을 확인하기 위해, 우리는 공간적으로 결맞은 영역 (청크, chunk) 에 담긴 전류 나선도를 추적했다. 그림 3(d) 에 나타난 시간적 진화는 나선도 응축의 명확한 징후를 보여주는데, 작은 규모의 청크들이 병합하여 더 큰 청크를 이루면서 우세 청크 (dominant chunk) 의 크기와 나선도 함유량이 함께 증가한다. 가장 큰 청크가 성장함에 따라 VAR 의 크기도 동시에 증가한다 (그림 3(e)). 이러한 결과는 활동영역의 진화가 자기 나선도의 역전달 (inverse transfer) 에 의해 지배되며, 이것이 플레어를 촉발할 수 있는 대규모·고에너지 구조의 형성을 이끈다는 것을 강하게 시사한다.




그림 3: AR 12673 의 전류 나선도 공간 분포와 청크 진화. (a) 세 시점에서의 시선방향 자기장. (b) 전류 나선도 분포; 녹색 선은 PIL. (c) 청크 마스크. (d) 청크 픽셀 수 대 총 나선도 산점도. (e) MEAN 항과 -VAR 항의 진화.

그림 3 상세분석: (a) 자기장 지도 — 세 시점에 걸쳐 작은 이극성에서 크고 복잡한 δ 형 구조로 급성장. (b) 전류 나선도 밀도 (파랑 = 음, 빨강 = 양) — 시간이 갈수록 음의 나선도 구조가 커지고 조직화됨 (초록선 = PIL). (c) 청크 마스크 — 첫 시점 작고 열은 단일 덩어리 → 크고 응집된 초승달/갈고리 모양 구조로 성장 (색 진하기 = 픽셀 수). (d) 산점도 +2D 히스토그램 — 시간이 갈수록 픽셀 수가 큰 성분과 헬리시티 크기가 큰 성분이 분리되어 지배적 청크가 커지며 음의 헬리시티가 강해짐을 보임. (e) 시계열 — 파란 곡선 (이미지 범례 기준 MEAN) 이 09-03 경부터 계단식으로 상승, 빨간 곡선 (이미지 범례 기준 -VAR) 은 더 늦게 (09-04 이후) 상승을 시작해 09-06 대형 플레어 직전 급피크.

역주 (캡션-이미지 색상 배정 충돌): 캡션은 “MEAN 항 (빨강) 과 -VAR 항 (파랑)” 으로 기술하나, 실제 이미지 범례-색상은 정반대로 **MEAN= 파랑**, **-VAR= 빨강**이다. 본문 (§5.1)의 MEAN·VAR 정의식은 이미지 범례와 정확히 일치하므로, 색상 오류는 캡션 쪽으로 판단된다. 독해 시 이미지 (및 본문 정의식) 기준을 채택할 것.

역할: 논문의 물리 메커니즘 증거. VAR 항이 실제로 나선도 응축 (작은 청크가 PIL 부근 최대 척도로 병합·응축) 과정을 포착함을 AR 12673 단일 사례로 시각화한다.

우리는 데이터셋에 포함된 1744 개 전체 HARP 에 대해 전류 나선도의 통계값 간 상관관계 분석을 수행했다. MEAN 항은 활동영역 전체와 관련된 다양한 통계값과 비교했고, VAR 항은 가장 큰 청크와 관련된 통계값과 각각 비교했다. 그 결과 $|MEAN|$ 과 (절대 net 나선도의 제곱) 사이의 상관관계는 $r = 0.87$, $|VAR|$ 과 가장 큰 결맞은 청크 내 전류 나선도 합의 제곱 사이의 상관관계는 $r = 0.79$ 로 나타났다 (그림 4 참조, 여기서 r 은 피어슨 상관관계수 (Pearson correlation coefficient) 이다). 그림 4 의 두 패널은 y 값 범위가 서로 비슷한데, 이는 모델이 대규모 나선도 농축과 활동영역 전체의 net 전류 나선도 제곱에 동등한 가중치를 부여함을 보여준다. MEAN 과 VAR 항의 부호가 서로 반대일 때, 모델은 사실상 활동영역 전체의 net 전류 나선도 제곱의 절댓값과 가장 큰 청크의 전류 나선도의 절댓값에 대한 가중합을 계산하는 셈이 된다. 이러한 거동은 나선도 응축의 맥락에서 가장 큰 청크가 위치하는 PIL 인근의 자기적 특징이 활동영역 전체 속성만큼이나 플레어 예측에 중요하다는 기존의 통설 (Schrijver 2007) 과 부합한다. 이는 광구 (photospheric) 경계에서 플레어 예측에 가장 중요한 영역이 어디인지에 대한 단서를 제공한다.




그림 4: 1744 개 전체 HARP 로부터 계산한 MEAN 항과 VAR 항의 높은 상관관계. 왼쪽: 절대 net 나선도의 제곱 대 절대 MEAN($r = 0.87$). 오른쪽: 최대 청크 내 전류 나선도 제곱의 합 대 절대 VAR($r = 0.79$).

그림 4 상세분석: 좌·우 두 개의 2D 히스토그램 (로그 컬러바) 과 빨간 선형 회귀선으로 구성된다. 좌 패널 제목은 " H^2_{Cabs} vs. $|MEAN|$ " 이며, 우 패널은 "최대 규모 h_c^2 합 vs. $|VAR|$ " 이다. 두 패널 모두 원점 부근에 데이터가 고밀도로 몰려 있고 양의 상관을 이루며 우상향 대각 분포를 보인다. 두 패널의 y 축 상한 스케일 (약 2×10^8) 이 유사하다.

역주 (상관계수 반올림 차이): 이미지 좌 패널 제목에 표기된 상관계수는 **pcc = 0.86** 인데, 캡션·본문은 모두 $r = 0.87$ 로 기재하고 있다 (우 패널은 0.79 로 양쪽 일치). 1 자리 차이로 반올림/판본 차이로 보이며 논문의 결론에는 영향을 주지 않는다.

역할: 논문의 통계적 일반화 근거. 그림 3 이 AR 12673 단일 사례였다면, 그림 4 는 전체 1744 개 HARP 전수에 대해 MEAN·VAR 항의 물리적 정체 (각각 AR 전체 순 나선도, 최대 청크의 나선도) 를 강한 상관으로 확정한다.

위에서 확인된 파라미터, 즉 가장 큰 결맞은 청크 (chunk) 내 전류 나선도 합의 제공이 갖는 예측 관련성을 추가로 평가하기 위해, 우리는 비선형 의존성 (nonlinear dependency) 을 포착하는 최대 정보 계수 (maximal information coefficient, MIC; Reshef et al. 2011) 를 사용하여 이 파라미터와 플레어 발생 사이의 연관성을 정량화했다. 놀랍게도, 이 파라미터는 18 개 SHARP 파라미터에 우리가 추가로 유도한 파라미터를 더한 총 19 개 변수 중 3 위 ($MIC = 0.067$) 를 차지했다. 이는 최상위 순위의 파라미터인 총 부호무시 (unsigned) 전류 나선도 (0.072) 와 총 부호무시 수직 전류 (0.069) 와 견줄 만한 수준인데, 이 두 파라미터는 모두 전류의 벌크 측도 (bulk measure) 에 해당한다. 결정적으로, 우리의 파라미터는 모델 입력으로 사용된 원래 SHARP 파라미터 중 하나인 net 전류 나선도의 절댓값 ($MIC = 0.063$) 뿐 아니라, R 값 (0.066) 과 부호무시 자속 (unsigned flux, 0.064) 을 비롯해 널리 사용되는 자속 기반 파라미터들보다도 더 우수한 성능을 보인다. 이처럼 높은 MIC 순위는 (우리 파라미터가 포착하는) 전류 나선도의 구조적 조직화가 전통적인 net 전류 나선도 측도나 총 자속, 혹은 퍼텐셜 에너지 단독보다 대규모 플레어에 대해 더 큰 예측 정보를 담고 있음을 확인해 준다.

5.3 모델 파라미터의 시간적 분해 (Temporal Decomposition of the Model Parameters)

모델이 순간 측정값이 아니라 24 시간 구간 내 최댓값 ($H_{c_{abs}}(t_{max})$) 에 의존한다는 사실은 플레어 예측에서 중요한 시간적 역학을 드러낸다. 모델은 두 가지 시간적 요인을 결합한다. 첫째는 net 전류 나선도 크기가 정점에 달하는 시점에서의 물리량이다. 둘째는 총 부호무시 전류 나선도의 진화 비율 (evolution ratio) 이다. 이 관계는 다음과 같은 분해를 따른다.

[별행 수식 — 원문 미확보] — $H_{c_{abs}}(t_{max})$ 의 시간 분해식이다. 본문에 따르면 (net 전류 나선도 크기가 최대가 되는 시점의 물리량) $\times$ (총 부호무시 전류 나선도의 진화 비율) 형태이다.

여기서 (원문 이미지 표기의) 기호들은 각각 $H_{c_{abs}}(t_{max})$ 및 관련 물리량을 나타낸다. 정점 배열 강도 (peak configuration strength) 와 이후의 나선도 진화 사이의 곱셈적 관계는 플레어 발생에 선행하는 에너지 축적 단계에 대한 통찰을 제공한다.

6 결론 (Conclusion)

이 레터는 딥러닝 (deep learning) 과 기호회귀 (symbolic regression, SR) 를 결합하여, 전통적인 모수적 (parametric) 모델에 견줄 만한 해석가능성 (interpretability) 을 유지하면서도 데이터로부터 예측 점수 (prediction score) 와 보정 확률 추정치 (calibrated probability estimate) 를 학습하는 비모수적 (nonparametric) 플레어 예보 모델을 제시한다. 우리의 해석가능한 대리 모델 (interpretable surrogate) 은 최고 성능의 BiLSTM-attention 기준 모델 (baseline) 과 동일한 TSS 를 달성하면서도, 자유도 (degrees of freedom) 는 4 자릿수 (orders of magnitude) 이상 더 적다. 더 나아가 우리의 경험적 분석 (empirical analysis) 은 SR 모델이 추출한 지배적 예측 변수 (dominant predictor) 가 가장 큰 공간적 결맞음 영역 (largest coherent chunk, 청크) 에서의 전류 나선도 (current helicity) 제곱합으로 해석될 수 있음을 보여주며, 이는 대규모 플레어 (major flare) 발생에서 최대 공간규모 (largest scale) 가 수행하는 역할을 부각한다. 이는 플레어 생산성이 높은 활동영역 (active region, AR) 에서 전류 나선도가 정캐스케이드 (forward cascade) 에 의해 주로 소산 (dissipate) 되기보다는, 역캐스케이드 (inverse cascade) 와 유사한 과정을 통해 대규모 (large scale) 로 우선적으로 전달되고 저장된다는 그림과 일치한다.

더 넓은 관점에서, 본 접근법은 SR 이 복잡한 신경망 (neural network) 예측을 천문학의 다른 문제에도 전이 가능한 (transferable) 간결하고 물리적으로 의미 있는 관계식으로 증류 (distill) 해낼

수 있음을 보여준다. 자연스러운 다음 단계는 더 짧은 입력 이력 (input history)(예: 6–12 시간) 과/또는 더 높은 시간 해상도 (cadence) 의 입력을 체계적으로 비교하여, 신뢰할 수 있는 예보에 필요한 최소 시간적 맥락 (minimum temporal context) 을 정량화하는 것이다. 많은 플레어 예보 연구가 관행적으로 12–24 시간 창 (window) 을 사용하므로, 이러한 검증을 통해 우리의 설정에서 실제로 필요한 이력의 길이를 명확히 할 수 있을 것이다. 특징 중요도 (feature importance) 패턴은 가장 유의미한 정보가 마지막 몇 개의 시간 스텝 (time step) 부근에 집중되어 있을 가능성을 시사한다.

사사 (Acknowledgments)

이 연구는 교육부 (Ministry of Education, MoE) 산하 한국연구재단 (National Research Foundation of Korea, NRF) 의 BK21 FOUR 사업 (경희대학교, Human Education Team for the Next Generation of Space Exploration), 경희대학교 대학원 BK21 FOUR 사업 (GSX-20242364, GS-5-JO-NON-20250797, GSX-20253142), 교육부 (MoE) 재원 NRF 지원 Global-Learning & Academic Research Institution for Master's and PhD students, and Postdocs(G-LAMP) Program(RS-2025-25442355), 대한민국 정부 (우주항공청, Korea AeroSpace Administration, KASA) 지원 과제 (과제번호 RS-2023-00234488, Development of Solar Synoptic Magnetograms Using Deep Learning), 그리고 대한민국 정부 (과학기술정보통신부, MSIT) 재원 NRF 과제 (RS-202400346061) 의 지원을 받았다. 또한 이 연구는 과학기술정보통신부 (Ministry of Science and ICT, MSIT) 감독하 한국천문연구원 (Korea Astronomy and Space Science Institute, KASI) 의 R&D 사업 (과제번호 2026-1-830-05) 의 지원을 받았다. G.S.C. 는 대한민국 정부 MSIT 재원 한국연구재단 (NRF) 과제 RS-2023-NR076760 의 지원을 받았다. 우리는 유럽연구위원회 집행기구 (European Research Council Executive Agency, ERC EA) 의 ERC-AdG 협약 No. 101141362(Open SESAME) 의 지원에 감사드린다. 또한 이 레터에서 사용한 도구들을 개발한 오픈소스 소프트웨어 커뮤니티의 값진 노력에도 감사드린다.

소프트웨어: PyTorch Lightning (Falcon & The PyTorch Lightning team 2019), SunPy (The SunPy Community et al. 2020), Astropy (Robitaille et al. 2013; Astropy Collaboration et al. 2022), SciPy (Virtanen et al. 2020), NumPy (Harris et al. 2020), Matplotlib (Hunter 2007).

A 데이터 전처리 (Data Preprocessing)

머신러닝을 위한 견고한 데이터셋을 구축하기 위해, 원시 SHARP 파라미터에 일련의 엄격한 전처리 단계를 적용했다.

A.1 데이터 필터링 (Data Filtering)

먼저, 관측 품질과 위치를 기준으로 데이터셋을 필터링했다. 투영 효과 (projection effect) 를 최소화하기 위해, SHARP 패치 경계 상자 (bounding box) 의 태양중심경도 (heliocentric longitude) 가 $\pm 70^\circ$ 를 벗어나는 관측을 제외했으며, 이는 해당 분야의 표준 관행 (Liu et al. 2019; Sun et al. 2022; Abdullah et al. 2023) 을 따른 것이다. 또한 신뢰할 수 있는 추적을 보장하기 위해, HMI 헤더에서 저품질 비트 (low-quality bit) 로 표시되었거나 NOAA AR 번호가 누락된 데이터 포인트를 제외했다.

A.2 복합 활동영역에 대한 플레어 연관 (Flare Association for Complex ARs)

태양 플레어 (solar flare) 를 특정 HMI 패치와 정확히 연관 짓는 일은 중요한데, 특히 여러 활동영역 (active region, AR) 이 서로 가까이 나타나는 경우 더욱 그러하다. 우리는 SHARP 메타데이터의 NOAA_ARS 헤더를 파싱 (parsing) 하여 이러한 복잡한 사례를 처리했다. 이를 통해 예보

구간 (forecasting window) 내에 기록된 모든 관련 GOES 플레어를 각각의 SHARP 패치에 정확히 대응시킬 수 있었으며, 이로써 혼잡한 태양면 구성에서도 플레어가 누락되거나 잘못 귀속되지 않도록 보장했다. 다만 이 레이블링 (labeling) 전략의 한계를 짚어둔다. SHARP 패치가 여러 NOAA AR 을 통합한 복합 HARP 에 해당하는 경우, 그 결과로 생기는 큰 경계 상자와 혼합된 영역 연관성은 단일 AR 패치와 비교했을 때 특징값 (feature value) 과 플레어 레이블 모두에 편향을 일으킬 수 있다. 따라서 우리는 이러한 복합 사례를 포함하는 것을 하나의 설계 선택 (design choice) 으로 간주하며, 향후 과제로서 (복합 HARP 를 제외하거나 대안적 연관 규칙을 사용하는 등의) 전용 민감도 분석 (sensitivity study) 을 고려한다. 아울러 이러한 복합 HARP 를 제외할 경우 주요 플레어 표본 수가 크게 줄어들 수 있으므로, 더 깨끗한 연관성 확보와 표본 보존 사이의 트레이드오프 (trade-off) 를 명시적으로 평가할 필요가 있음을 언급해 둔다.

A.3 시계열 구성 및 결측치 대체 (Time Series Construction and Imputation)

각 표본에 대해, 96 분 간격의 16 개 시간 단계 (time step) 로 구성된 24 시간 입력 시퀀스 (sequence) 를 구성했다. 지나치게 엄격한 완전 사례 분석 (complete case analysis; 유의미한 데이터를 과도하게 버리게 되는 방식) 에 의존하지 않으면서 데이터 무결성 (integrity) 을 유지하기 위해, 다음과 같은 보수적인 결측치 대체 (imputation) 전략을 채택했다.

1. 파라미터별로 결측값이 최대 2 개인 시퀀스만 보존했다.
2. 예보에 가장 중요한 지점이므로, 마지막 시간 단계 (t) 는 반드시 결측이 없어야 한다는 조건을 부과했다.
3. 나머지 결측 구간은 후진 채움 (backward fill) 방법으로 메웠는데, 이는 결측값을 채우기 위해 다음으로 유효한 관측값을 시간상 뒤로 (과거 방향으로) 전파하는 방식이다.

A.4 레이블링 (Labeling)

예보 구간 ($t, t + 24 \text{ hr}$] 을 기준으로, 시퀀스를 두 개의 클래스 (class) 로 분류했다. “플레어 발생 (flaring)” 시퀀스는 해당 구간 내에 M-class 이상의 플레어가 하나 이상 뒤따르는 경우로 정의한다. “평온 (quiet)” 시퀀스는 해당 구간 내에 M-class 이상의 플레어가 전혀 없는 경우이다. 그 결과 최종 데이터셋은 3462 개의 플레어 발생 시퀀스와 150,898 개의 평온 시퀀스로 구성되었다. 이러한 이진 분류 (binary classification) 구성은 주요 태양 플레어 사건의 개시 (onset) 와 지속 (continuation) 을 예측하는 데 초점을 둔다.

B 지표 및 교차검증 결과 (Metrics and Cross-validation Results)

이 부록은 모델 평가에 사용된 지표 (metric) 들의 공식 정의를 제공하고, 딥러닝 모델과 SR 모델 모두에 대한 5 겹 교차검증 (fivefold cross-validation) 의 상세 결과를 정리한다.

B.1 보정 및 예보 지표 (Calibration and Forecasting Metrics)

확률적 보정 (probabilistic calibration) 은 경험적 누적 보정 오차 (empirical cumulative calibration error, ECCE) 지표 (Arrieta-Ibarra et al. 2022), 구체적으로는 최대 절대편차 (maximum absolute deviation, ECCE-MAD) 와 범위 (range, ECCE-R) 를 사용해 평가한다. 표본은 예측 확률 (predicted probability) 에 따라 정렬한다. 이 순서에서 j 번째 표본에 대해 R_j 를 실제 결과 (0 또는 1), S_j 를 예측 확률이라 하고, n 을 전체 표본 수라 하자. 누적 차이는 $1 \leq k \leq n$ 에 대해 [식 — 원문 미확보; 문맥상 $C_k = \frac{1}{n} \sum_{j=1}^k (R_j - S_j)$ 형태] 로 정의하며, $C_0 = 0$ 이다. 이로부터 ECCE-MAD [식 — 원문 미확보; 콜모고로프-스미르노프 통계량 (Kolmogorov-Smirnov statistic), $\max_k |C_k|$]

형태] 와 ECCE-R [식 — 원문 미확보; $\max_k C_k - \min_k C_k$ 형태] 를 각각 도출한다. 값이 작을수록 보정 성능이 우수함을 의미한다.

플레이어 예보 성능은 다음 지표들을 사용해 추가로 정량화한다.

[별행 수식 — 원문 미확보] — 표준 예보 성능 지표 정의식 (Accuracy, Precision, Recall, FAR, F1, TSS, HSS 등). 이들은 혼동행렬 (confusion matrix; TP, TN, FP, FN) 기반의 표준 정의를 따른다.

여기서 [식 — 원문 미확보] 는 브라이어 기술 점수 (Brier skill score, BSS; Brier 1950) 이며 (p_i : 예측 확률, o_i : 관측된 결과), BSS_{ref} 는 기후학적 기준 예보 (climatological reference forecast) 의 브라이어 기술 점수이다. 별도로 명시하지 않는 한, 모든 지표는 0.5 의 결정 임계값 (decision threshold) 을 사용해 계산한다.

B.2 교차검증 결과 (Cross-validation Results)

네 가지 딥러닝 아키텍처 (architecture) 와 증류된 (distilled) SR 모델의 성능을 5 겹 교차검증을 사용해 평가했다. 결과는 각 폴드 (fold) 전반에 걸친 평균 $\pm$ 표준편차로 보고한다.

B.2.1. 보정 전 성능 (고정 임계값 0.5)

0.5 의 고정 결정 임계값에서, 테스트 세트 (test set) 성능은 다음과 같다. 지표는 Accuracy, Precision, Recall, FAR, F1, TSS, HSS, 조화평균 (harmonic mean), BSS 순서로 보고한다 (5 개 폴드에 걸친 평균 $\pm$ 표준편차; 소수점 둘째 자리까지).

모델	Accuracy	Precision	Recall	FAR	F1	TSS	HSS	조화평균	BSS
LSTM	0.97 $\pm$ 0.01	0.43 $\pm$ 0.13	0.29 $\pm$ 0.07	0.57 $\pm$ 0.13	0.33 $\pm$ 0.08	0.28 $\pm$ 0.06	0.32 $\pm$ 0.08	0.29 $\pm$ 0.06	-0.05 $\pm$ 0.38
LSTM-attention	0.98 $\pm$ 0.01	0.50 $\pm$ 0.09	0.30 $\pm$ 0.07	0.50 $\pm$ 0.09	0.37 $\pm$ 0.08	0.29 $\pm$ 0.07	0.36 $\pm$ 0.08	0.32 $\pm$ 0.07	0.12 $\pm$ 0.10
BiLSTM	0.97 $\pm$ 0.00	0.41 $\pm$ 0.14	0.30 $\pm$ 0.06	0.59 $\pm$ 0.14	0.34 $\pm$ 0.07	0.29 $\pm$ 0.06	0.33 $\pm$ 0.07	0.31 $\pm$ 0.06	0.03 $\pm$ 0.15
BiLSTM-attention	0.98 $\pm$ 0.00	0.75 $\pm$ 0.09	0.43 $\pm$ 0.15	0.25 $\pm$ 0.09	0.53 $\pm$ 0.13	0.42 $\pm$ 0.15	0.52 $\pm$ 0.13	0.47 $\pm$ 0.14	0.38 $\pm$ 0.08
SR	0.94 $\pm$ 0.01	0.22 $\pm$ 0.04	0.66 $\pm$ 0.09	0.78 $\pm$ 0.04	0.33 $\pm$ 0.04	0.60 $\pm$ 0.09	0.31 $\pm$ 0.05	0.40 $\pm$ 0.05	-1.03 $\pm$ 0.44

표 3: 보정 전 성능 (고정 임계값 0.5).

TSS 와 HSS 의 조화평균이 가장 높다는 기준에 따라, BiLSTM-attention 이 이후 증류를 위한 대표 딥러닝 모델로 선정되었다.

B.2.2. 등장회귀 보정 후 성능 (최적화된 임계값)

검증 세트 (validation set) 에서 TSS 와 HSS 의 조화평균을 최대화하도록 등장회귀 (isotonic regression) 와 임계값 최적화 (threshold optimization) 를 적용한 후, 성능 지표는 다음과 같다. 지표는 Accuracy, Precision, Recall, 오경보율 (false alarm rate, FAR), F1, TSS, HSS, 조화평균, BSS, ECCE-MAD, ECCE-R 순서로 보고한다 (5 개 폴드에 걸친 평균 $\pm$ 표준편차; 성능 지표는 소수점 둘째 자리까지, ECCE 는 셋째 자리까지).

모델	Accuracy	Precision	Recall	FAR	F1	TSS	HSS	조화평균	BSS	ECCE-MAD	ECCE-R
LSTM	0.96 $\pm$ 0.01	0.32 $\pm$ 0.10	0.41 $\pm$ 0.18	0.68 $\pm$ 0.10	0.32 $\pm$ 0.06	0.38 $\pm$ 0.16	0.30 $\pm$ 0.06	0.33 $\pm$ 0.10	0.16 $\pm$ 0.07	0.005 $\pm$ 0.001	0.006 $\pm$ 0.001
LSTM-attention	0.96 $\pm$ 0.00	0.26 $\pm$ 0.04	0.54 $\pm$ 0.12	0.74 $\pm$ 0.04	0.35 $\pm$ 0.04	0.51 $\pm$ 0.11	0.33 $\pm$ 0.04	0.39 $\pm$ 0.06	0.19 $\pm$ 0.08	0.005 $\pm$ 0.003	0.005 $\pm$ 0.003
BiLSTM	0.96 $\pm$ 0.02	0.28 $\pm$ 0.03	0.43 $\pm$ 0.16	0.72 $\pm$ 0.03	0.33 $\pm$ 0.04	0.40 $\pm$ 0.15	0.31 $\pm$ 0.04	0.34 $\pm$ 0.08	0.18 $\pm$ 0.06	0.005 $\pm$ 0.001	0.006 $\pm$ 0.001
BiLSTM-attention	0.98 $\pm$ 0.01	0.58 $\pm$ 0.19	0.57 $\pm$ 0.12	0.42 $\pm$ 0.19	0.55 $\pm$ 0.12	0.56 $\pm$ 0.11	0.54 $\pm$ 0.12	0.54 $\pm$ 0.09	0.38 $\pm$ 0.10	0.004 $\pm$ 0.001	0.004 $\pm$ 0.001
SR	0.96 $\pm$ 0.01	0.34 $\pm$ 0.08	0.52 $\pm$ 0.18	0.66 $\pm$ 0.08	0.38 $\pm$ 0.04	0.50 $\pm$ 0.17	0.36 $\pm$ 0.04	0.41 $\pm$ 0.07	0.21 $\pm$ 0.04	0.005 $\pm$ 0.004	0.006 $\pm$ 0.003

표 4: 등장회귀 보정 후 성능 (최적화된 임계값).

C PySR 전체 표현식 목록 (Full PySR Expression List)

향후 참고를 위해, 대표 모델 탐색 (전체 데이터셋 피팅, full dataset fitting) 에 대해 PySR 이 반환한 최적합 후보 표현식 (expression) 의 전체 목록을 보고된 모든 복잡도 (complexity) 수준에 걸쳐 제공한다. 이 표현식들은 PySR 출력 형태로 작성되었으며 $P_{\geq M}$ 에 대한 로짓 공간 (logit-space) 모델에 해당한다. 아래의 모든 표현식은 $\text{logit}(P_{\geq M}(t))$ 를 모델링한다. 가독성을 위해 아래 목록에서는 반복되는 접두어 " $\text{logit}(P_{\geq M}(t)) =$ " 를 생략한다. MSE 값은 소수점 셋째 자리까지 반올림했다.

해석을 돕기 위해, 식 (1) 의 표기법을 사용하여 PySR 표현식을 다시 작성한다. 마지막 시간 단계에서의 R -값은 $R(t)$ 로, k 단계 이전의 값은 $R(t - k\Delta t)$ 로 표기한다. 구체적으로, 길이 16 의 입력 창 (window) 에 대한 시퀀스 통계량은 각각 최솟값·중앙값·평균값에 대해 $R_{\min}$, R_{median} , R_{mean} 으로 표기한다.

[주: 아래 복잡도별 표현식 중 상당수가 원문에서 별행 수식 이미지로 표시되어 HTML 추출 시 누락되었다. 텍스트로 확보된 항목 (복잡도 1, 7) 과 표 1 에서 확보된 항목 (복잡도 15, 17, 19, 20) 만 정확한 식을 제시하고, 나머지는 위치·MSE 를 보존한다. 정확한 수식·상수는 출판사 PDF 확보 시 보강이 필요하다.]

1. **복잡도 1** (MSE 8.167): -1.5905691
2. **복잡도 3** (MSE 3.427): [별행 수식 — 원문 미확보]
3. **복잡도 5** (MSE 1.652): [별행 수식 — 원문 미확보]
4. **복잡도 6** (MSE 1.431): [별행 수식 — 원문 미확보]
5. **복잡도 7** (MSE 1.349): $0.42378628 R(t - 3\Delta t) R(t) - 9.765469$
6. **복잡도 8** (MSE 1.327): [별행 수식 — 원문 미확보]
7. **복잡도 9** (MSE 1.297): [별행 수식 — 원문 미확보]
8. **복잡도 10** (MSE 1.243): [별행 수식 — 원문 미확보]
9. **복잡도 12** (MSE 1.228): [별행 수식 — 원문 미확보]
10. **복잡도 13** (MSE 1.205): [별행 수식 — 원문 미확보]
11. **복잡도 14** (MSE 1.193): [별행 수식 — 원문 미확보]
12. **복잡도 15** (MSE 1.165): $C_{13} R(t - 2\Delta t) R(t) - \frac{C_{14}}{R(t - 3\Delta t) H_{c_{\text{abs}}}(t_{\text{max}}) + C_{15}} - C_{16}$
13. **복잡도 17** (MSE 1.131): $C_9 R(t - 3\Delta t) R(t) - \frac{C_{10}}{H_{c_{\text{total}}}(t) H_{c_{\text{abs}}}(t_{\text{max}}) + C_{11}} - C_{12}$
14. **복잡도 19** (MSE 1.114): $C_5 R(t - 2\Delta t) R(t) - \frac{C_6}{R(t - 3\Delta t) H_{c_{\text{total}}}(t) H_{c_{\text{abs}}}(t_{\text{max}}) + C_7} - C_8$
15. **복잡도 20** (MSE 1.112): $C_1 R(t - 2\Delta t) R(t) - \frac{C_2}{R^2(t - 3\Delta t) H_{c_{\text{total}}}(t) H_{c_{\text{abs}}}(t_{\text{max}}) + C_3} - C_4$

Note. 여기서 C_n 은 PySR 이 피팅한 상수 계수 (constant coefficient) 를 통칭한다.

문맥 조정 기록

#	위치	조정 내용	사유
1	전체 문서	TSS 번역을 "참 기술 통계량 (TSS)" 로 통일	ch01 표기 기준, HSS·BSS와 용어 통일
2	전체 문서	HSS 번역을 "하이드케 기술 점수 (HSS)" 로 통일	상동
3	전체 문서	BSS 번역을 "브라이어 기술 점수 (BSS)" 로 통일	상동
4	§4.3, 초록	"전류 나선도 상호작용 항"→"전류 나선도 상호작용항"(공백 제거)	챕터 간 띄어쓰기 불일치 통일
5	§3.1 (2 곳)	"5 겹 교차 검증"→"5 겹 교차검증"(공백 제거)	챕터 간 띄어쓰기 불일치 통일
6	결론 (§6)	"largest coherent chunk" 뒤에 "(청크)" 병기 추가	§5.2 의 "청크" 용어와 연결성 보강
7	§1, §4.3, §5.2	그림 1-4·표 1 캡션 뒤에 이미지 삽입 및 "상세분석" 소블록 추가	figure-analyst 의 시각 해석·역주를 본문에 반영
8	문서 서두	원문 확보 한계에 대한 일러두기를 1 회 배치	반복 안내로 인한 가독성 저하 방지
9	전 챕터	각 챕터 말미의 "번역 노트"·"전문용어 목록" 은 통합본에서 제거	지침에 따라 본문 제외, 용어표에 반영

남은 한계

별행 (displayed) 수식 원문 미확보 위치는 총 11 곳이다: §4.3 정의식 1 곳 ($H_{c_{total}} \cdot H_{c_{abs}}$ 정의), §5.1 정의식·분해식 3 곳, §5.3 시간 분해식 1 곳, 부록 B.1 지표 정의식 4 곳 (누적차이·ECCE-MAD·ECCE-R·BSS), 부록 C 표현식 9 곳 (복잡도 3·5·6·8·9·10·12·13·14). 인접 본문·그림 범례에서 확인 가능한 정보는 각 위치에 병기했다. 그림 2(a) x 축 캡션 표기, 그림 3(e) 색상 배정, 그림 4 좌 상관 계수 소수점 표기는 원문 자체의 캡션·이미지 불일치이며, 번역 과정에서 발생한 오류가 아니다.